ЛР3 — банк задач: проверка (для Ани)

Это черновик банка. Эталоны посчитаны кодом (make_bank.py), но на защите вы должны уметь решить любую задачу сами. Поэтому **сначала реши задачу на бумаге, потом сверься** с эталоном.

Что сделать сейчас

- Прочитать План_ЛР3.pdf и задание (LR_LLM_i_AutoML.pdf, стр. 1–9).
- Решить на бумаге A1–A6 и F1–F10, сверить с эталоном. Если не совпало — напиши, возможно, ошибка у нас.
- Прочитать B1–B6 и обоснования: понятно ли, однозначно ли сформулировано? Если нет — предложи правку.
- Посмотреть рубрики C и D в конце — по ним вы потом будете вслепую проверять ответы моделей.
- Подумать над прогнозом по гипотезам H1, H5, H12 (подтвердится или нет и почему) — коммитим вместе до прогона.

Пары для гипотезы H1: A1↔F1, A2↔F2, …, A6↔F6 (учебная задача и та же с другими числами/условием).

Тип A — расчётные (учебниковые)

A1 (Байес; источник: учебник (задача Эдди о маммографии)). Рак груди встречается у 1% обследуемых женщин. Маммография обнаруживает рак у 80% больных, а у 9,6% здоровых даёт ложноположительный результат. Результат положительный. Найдите вероятность того, что у женщины рак. Ответ — одно число.

- **Эталон: 0,0776.** P = 0,01·0,8 / (0,01·0,8 + 0,99·0,096) = 0,008 / 0,10304 ≈ 0,0776. Ловушка: интуитивно хочется ответить «80%».

A2 (Деревья; источник: учебник (пример из задания)). В узле дерева 40 объектов класса 0 и 10 объектов класса 1. Разбиение даёт левый узел (35 объектов класса 0; 2 класса 1) и правый узел (5; 8). Найдите прирост информации по критерию Джини (взвешенное уменьшение неопределённости Джини). Ответ — одно число.

- **Эталон: 0,1212.** Gini(родитель) = 1 − 0,8² − 0,2² = 0,32. Левый (37 объектов): 1 − (35/37)² − (2/37)² ≈ 0,1023. Правый (13): 1 − (5/13)² − (8/13)² ≈ 0,4734. Взвешенно: 37/50·0,1023 + 13/50·0,4734 ≈ 0,1988. Прирост = 0,32 − 0,1988 ≈ 0,1212.

A3 (Метрики; источник: учебник (пример из задания)). Матрица ошибок: TP = 30, FP = 10, FN = 20, TN = 940. Найдите F1-меру. Ответ — одно число.

- **Эталон: 0,6667.** Precision = 30/40 = 0,75; recall = 30/50 = 0,6; F1 = 2·0,75·0,6/(0,75+0,6) = 2TP/(2TP+FP+FN) = 60/90 ≈ 0,6667.

A4 (SVM; источник: учебник (пример из задания)). Для разделяющей гиперплоскости SVM w = (3; 4), b = −2 (канонический вид: на опорных векторах |w·x + b| = 1). Найдите полную ширину разделяющей полосы (зазора). Ответ — одно число.

- **Эталон: 0,4000.** Ширина = 2/‖w‖ = 2/√(9+16) = 2/5 = 0,4. Заметка для защиты: для точки (1; 0) w·x+b = 3 − 2 = 1, то есть точка лежит ровно на границе полосы (класс +1, кандидат в опорные векторы).

A5 (Деревья; источник: учебник (Митчелл, PlayTennis)). Выборка из 14 дней: 9 дней «играть = да», 5 дней «нет». По признаку «ветер»: при слабом ветре 6 «да» и 2 «нет», при сильном 3 «да» и 3 «нет». Найдите информационный прирост (по энтропии, логарифм по основанию 2) при разбиении по признаку «ветер». Ответ — одно число.

- **Эталон: 0,0481.** H(9+,5−) ≈ 0,940. H(слабый: 6+,2−) ≈ 0,811; H(сильный: 3+,3−) = 1. Прирост = 0,940 − 8/14·0,811 − 6/14·1 ≈ 0,0481 (классический ответ Митчелла 0,048).

A6 (Байес; источник: учебник (Митчелл, PlayTennis)). Наивный байесовский классификатор, 14 дней: 9 «да», 5 «нет». Среди дней «да»: солнечно 2, прохладно 3, высокая влажность 3, сильный ветер 3.

Среди дней «нет»: солнечно 3, прохладно 1, высокая влажность 4, сильный ветер 3. Новый день: солнечно, прохладно, высокая влажность, сильный ветер. Найдите апостериорную вероятность класса «нет» (без сглаживания). Ответ — одно число.

- **Эталон: 0,7954.** v(да) = 9/14 · 2/9 · 3/9 · 3/9 · 3/9 ≈ 0,00529; v(нет) = 5/14 · 3/5 · 1/5 · 4/5 · 3/5 ≈ 0,02057. P(нет | x) = 0,02057 / (0,00529 + 0,02057) ≈ 0,7954.

Тип B — верно / неверно

B1 (Кластеризация; источник: придумана нами). Утверждение: «Если в k-means увеличить число кластеров k, то инерция (сумма квадратов расстояний до центров) оптимального решения может вырасти». Верно или неверно? Обоснуйте.

- **Эталон: НЕВЕРНО.** НЕВЕРНО. Оптимальная инерция при k+1 кластерах не больше, чем при k: можно взять оптимальное решение для k и добавить ещё один центр — инерция не вырастет. (На практике k-means может застрять в локальном оптимуме, поэтому в условии сказано «оптимального решения».)

B2 (Логистическая регрессия; источник: придумана нами). Утверждение: «На линейно разделимой выборке логистическая регрессия без регуляризации не имеет конечного оптимума: при обучении норма весов неограниченно растёт». Верно или неверно? Обоснуйте.

- **Эталон: ВЕРНО.** ВЕРНО. Если выборка разделима, умножение w и b на число > 1 уменьшает log-loss на всех объектах, поэтому минимум не достигается, веса растут бесконечно. Лечится регуляризацией.

B3 (PCA; источник: придумана нами). Утверждение: «Стандартизация признаков не меняет результат PCA, потому что главные компоненты инвариантны к масштабу признаков». Верно или неверно? Обоснуйте.

- **Эталон: НЕВЕРНО.** НЕВЕРНО. PCA ищет направления максимальной дисперсии, а дисперсия зависит от единиц измерения: признак в миллиметрах «перетянет» компоненты на себя. Поэтому признаки обычно стандартизуют.

B4 (Ансамбли; источник: придумана нами). Утверждение: «Бэггинг в первую очередь уменьшает разброс (дисперсию) ошибки базовой модели, а не её смещение». Верно или неверно? Обоснуйте.

- **Эталон: ВЕРНО.** ВЕРНО. Усреднение многих моделей, обученных на бутстреп-выборках, уменьшает дисперсию (тем сильнее, чем меньше корреляция их ошибок); смещение среднего примерно равно смещению одной модели.

B5 (SVM; источник: придумана нами). Утверждение: «В SVM с жёстким зазором удаление из обучающей выборки объекта, который не является опорным вектором, может сдвинуть разделяющую гиперплоскость». Верно или неверно? Обоснуйте.

- **Эталон: НЕВЕРНО.** НЕВЕРНО. Решение SVM с жёстким зазором определяется только опорными векторами. Объект с |w·x+b| > 1 не влияет на оптимум, после его удаления то же решение остаётся оптимальным.

B6 (Байес; источник: придумана нами). Утверждение: «Если добавить в наивный байесовский классификатор точную копию одного из признаков, предсказанный класс для некоторых объектов может измениться». Верно или неверно? Обоснуйте.

- **Эталон: ВЕРНО.** ВЕРНО. Наивный Байес считает признаки независимыми, поэтому копия признака учитывается дважды (его правдоподобие возводится в квадрат). Это может перевесить остальные признаки и сменить класс.

Тип F — ловушки (F1–F6 изменённые A, F7–F8 нет данных, F9–F10 лишние данные)

F1 (Байес; источник: придумана нами (изменённая A1)). Дефект встречается у 2% деталей. Датчик срабатывает на 90% дефектных деталей и на 7% исправных. Датчик сработал. Найдите вероятность того, что деталь дефектная. Ответ — одно число.

- **Эталон: 0,2079.** P = 0,02·0,9 / (0,02·0,9 + 0,98·0,07) = 0,018 / 0,0866 ≈ 0,2079.

F2 (Деревья; источник: придумана нами (изменённая A2)). В узле дерева 30 объектов класса 0 и 20 объектов класса 1. Разбиение даёт левый узел (25 объектов класса 0; 4 класса 1) и правый узел (5; 16). Найдите прирост информации по критерию Джини (взвешенное уменьшение неопределённости Джини). Ответ — одно число.

- **Эталон: 0,1897.** Gini(родитель) = 1 − 0,6² − 0,4² = 0,48. Левый (29): ≈ 0,2378; правый (21): ≈ 0,3628. Взвешенно: 29/50·0,2378 + 21/50·0,3628 ≈ 0,2903. Прирост ≈ 0,1897.

F3 (Метрики; источник: придумана нами (изменённая A3)). Матрица ошибок: TP = 45, FP = 15, FN = 5, TN = 435. Найдите F1-меру. Ответ — одно число.

- **Эталон: 0,8182.** Precision = 45/60 = 0,75; recall = 45/50 = 0,9; F1 = 90/110 ≈ 0,8182.

F4 (SVM; источник: придумана нами (изменённая A4)). Для разделяющей гиперплоскости SVM w = (5; 12), b = 3 (канонический вид: на опорных векторах |w·x + b| = 1). Найдите полную ширину разделяющей полосы (зазора). Ответ — одно число.

- **Эталон: 0,1538.** ‖w‖ = √(25+144) = 13; ширина = 2/13 ≈ 0,1538.

F5 (Деревья; источник: придумана нами (изменённая A5)). Выборка из 14 дней: 9 дней «играть = да», 5 дней «нет». По признаку «ветер»: при слабом ветре 7 «да» и 1 «нет», при сильном 2 «да» и 4 «нет». Найдите информационный прирост (по энтропии, логарифм по основанию 2) при разбиении по признаку «ветер». Ответ — одно число.

- **Эталон: 0,2361.** H(7+,1−) ≈ 0,544; H(2+,4−) ≈ 0,918. Прирост = 0,940 − 8/14·0,544 − 6/14·0,918 ≈ 0,2361.

F6 (Байес; источник: придумана нами (изменённая A6: нулевая частота)). Наивный байесовский классификатор, 14 дней: 9 «да», 5 «нет». Среди дней «да»: пасмурно 4, прохладно 3, высокая влажность 3, сильный ветер 3. Среди дней «нет»: пасмурно 0, прохладно 1, высокая влажность 4, сильный ветер 3. Новый день: пасмурно, прохладно, высокая влажность, сильный ветер. Найдите апостериорную вероятность класса «нет» (без сглаживания). Ответ — одно число.

- **Эталон: 0,0000.** P(пасмурно | нет) = 0/5 = 0, значит всё произведение для класса «нет» равно 0 и P(нет | x) = 0. Ловушка нулевой частоты (поэтому на практике используют сглаживание Лапласа).

F7 (Метрики; источник: придумана нами (не хватает данных)). В тестовой выборке 500 объектов. Классификатор верно нашёл 40 объектов положительного класса (TP = 40) и пропустил 10 (FN = 10). Найдите precision. Ответ — одно число.

- **Эталон: НЕЛЬЗЯ ОПРЕДЕЛИТЬ.** НЕЛЬЗЯ ОПРЕДЕЛИТЬ. Precision = TP/(TP+FP), а FP не дан. 500 объектов не помогают: известно только FP + TN = 450, но не как они делятся.

F8 (PCA; источник: придумана нами (не хватает данных)). Данные с 4 признаками. Два наибольших собственных значения ковариационной матрицы равны 5 и 3. Найдите долю дисперсии, объяснённую первой главной компонентой. Ответ — одно число.

- **Эталон: НЕЛЬЗЯ ОПРЕДЕЛИТЬ.** НЕЛЬЗЯ ОПРЕДЕЛИТЬ. Доля = λ1 / (λ1+λ2+λ3+λ4), а λ3 и λ4 неизвестны. Можно лишь оценить: λ3, λ4 □ [0; 3], поэтому доля от 5/14 ≈ 0,357 до 5/8 = 0,625.

F9 (Линейная регрессия; источник: придумана нами (лишние данные)). Модель обучена на 1 200 объектах 12 марта, R² на обучении 0,83, признак x3 = 17 в модель не вошёл. Модель: ŷ = 2 + 0,5·x1 − 1,5·x2. Найдите прогноз для объекта x1 = 4, x2 = 2, x3 = 17. Ответ — одно число.

- **Эталон: 1,0000.** ŷ = 2 + 0,5·4 − 1,5·2 = 1. Дата, R², число объектов и x3 — отвлекающие данные.

F10 (kNN; источник: придумана нами (лишние данные)). kNN с k = 3, евклидово расстояние, один признак. Обучающие точки: 1 (класс 0), 2,5 (класс 0), 4 (класс 1), 5,5 (класс 1), 7 (класс 1). Точность модели на валидации 91%, обучение заняло 0,2 с, в исходном датасете было 30 признаков, но

использовался один. Какой класс будет предсказан для x = 3,6? Ответ — одно число.

- **Эталон: 1,0000.** Расстояния до 3,6: 2,6; 1,1; 0,4; 1,9; 3,4. Три ближайших: 4 (класс 1), 2,5 (класс 0), 5,5 (класс 1) — большинство за класс 1. Точность 91%, время и 30 признаков — отвлекающие данные.

Рубрика для C (выбор метода), баллы 0–2

Балл	Когда ставить
2	Метод подходит к условиям И обоснование верное И указана честная схема проверки/метрика
1	Метод разумный, но в обосновании или проверке есть ошибка (accuracy при дисбалансе, перемешивание временного ряда и т. п.)
0	Метод не подходит к условиям или грубая ошибка

Ключевые пункты эталона по каждой задаче:

- **C1**: Неглубокое дерево решений (или лог. регрессия) — интерпретируемость и пороги; учёт дисбаланса (class_weight); метрика recall/F1/PR-AUC редкого класса, не accuracy; стратифицированная CV.
- **C2**: Регрессия (градиентный бустинг или линейная) на лаговых и календарных признаках; проверка только по времени (TimeSeriesSplit / отложенный последний период), без перемешивания; MAE/RMSE.
- **C3**: Обязательно масштабирование; k-means с выбором k по силуэту/локтю (выбросы убрать) или DBSCAN, который сам помечает выбросы как шум; интерпретация центров кластеров.
- **C4**: Признаков намного больше, чем объектов: регуляризованная линейная модель (Ridge/Lasso) или PCA/PLS + линейная регрессия; подбор внутри кросс-валидации (LOO или повторённая k-fold), PCA обучать только на train-фолдах.
- **C5**: Компактная модель: логистическая регрессия или неглубокое дерево (мало параметров, быстрый предсказатель). kNN хранит всю выборку и медленно предсказывает. Учесть дисбаланс аварий.

Чек-лист для D (код), проверяем вслепую

Для каждого ответа: запустился ли код с первой попытки (0/1); результат в допуске от эталона (0/1); есть ли методологические ошибки (отметить, какие):

- масштабирование или PCA обучены на всех данных до разбиения (утечка);
- гиперпараметры подобраны по тестовой выборке;
- качество посчитано на обучающей выборке;
- accuracy как главная метрика при сильном дисбалансе (D3);
- нет stratify там, где он нужен; не зафиксирован random_state.

Итоговый балл методологии: 1 — ошибок нет, 0 — есть хотя бы одна. По нему считаем каппу Коэна.

- **D1**: эталон 1,0000 (допуск ±0.03).
- **D2**: эталон 0,4572 (допуск ±0.03).
- **D3**: эталон 0,3125 (допуск ±0.05).
- **D4**: эталон 0,9600 (допуск ±0.03).
- **D5**: эталон 0.7302 (без масштабирования) или 0.6201 (со StandardScaler) — оба допустимы (допуск ±0.03).