ЛР3: можно ли доверять LLM в задачах ML — план на двоих

Принцип: делаем **ровно то, что требует задание**, без лишнего. Всё, что можно, делает Claude Code. За нами то, что по правилам обязан делать человек, и подготовка к защите.

1. Суть работы в пяти пунктах

- Составить банк из **32 задач** по ML с правильными ответами (6 типов: A–F).
- Прогнать банк через **4 модели** с одним и тем же промптом и температурой 0.
- **До прогона** записать 3 гипотезы и свой прогноз и сделать git-коммит. После прогона проверить, подтвердились ли они.
- Посчитать точность с доверительными интервалами, сравнить модели тестом Макнемара, построить графики.
- Отчёт + доклад на 5 минут. На защите могут попросить перезапустить ячейку, объяснить любую строку кода, решить любую задачу из банка.

Опровергнутая гипотеза оценивается так же, как подтверждённая. Главное — честный эксперимент.

2. Чем мы отличаемся от одногруппников (их оценка 7/10)

У них	У нас
1 российская модель, нет локальной	GigaChat + Alice AI LLM + локальная Qwen3-4B, как требует задание
Банк слишком лёгкий: у всех ~100%, сравнивать нечего	Свои числа, многошаговые расчёты и ловушки: ждём заметно меньше 100%
Гипотезы H3, H6, H10	Гипотезы H1, H5, H12
C и D проверяли две LLM	C и D проверяем мы сами, вслепую, считаем каппу
Тип E: 100 строк одним промптом, breast_cancer	Одна строка = один запрос, датасет AI4I 2020
Цена GigaChat «н/д»	Цена по официальным пакетам Сбера
Сложный код (пакеты, Docker, CLI)	1 файл с функциями + 3 ноутбука

3. Модели (ровно 4)

Роль	Модель	Доступ
Российская №1	GigaChat-2-Max	Ключ уже есть, бесплатный лимит на год
Российская №2	Alice AI LLM	Yandex AI Studio, стартовый грант Yandex Cloud
Большая открытая	DeepSeek V4.1 Flash	Тот же ключ Yandex AI Studio (Qwen3-235B из каталога убрали)
Маленькая локальная	Qwen3-4B	Ollama на ноутбуке, бесплатно

Три модели из четырёх работают через один и тот же OpenAI-совместимый интерфейс, поэтому код получается коротким. Точные ID моделей и дату запросов записываем в лог автоматически.

4. Гипотезы

Взяты так, чтобы **не требовать дополнительных экспериментов**: всё считается из обязательных прогонов.

Группа	Гипотеза	Чем проверяем
1. Рассуждение или запоминание	**H1. Изменённые числа.** На учебниковых задачах точность выше, чем на тех же задачах с изменёнными числами	6 пар: учебная задача A ↔ её изменённая копия в F
2. Размер модели	**H5. Размер модели.** Маленькая модель отстаёт от больших сильнее в расчётах (A), чем в теории (B)	Разница точности «большие − Qwen3-4B» на A и на B
4. LLM против классики	**H12. LLM-классификатор.** При 5 примерах LLM не хуже логистической регрессии, при 20 — проигрывает	Тип E: F1 и balanced accuracy LLM и LogReg на 5 и 20 примерах

Прогноз пишете **вы сами** (1–2 предложения на гипотезу: подтвердится или нет и почему). Его коммитим до прогона.

5. Банк задач: 32 + 5 пилотных

Тип	Сколько	Что внутри	Как проверяем
A — расчёт	6	Учебниковые: Байес, Джини, метрики, SVM, сигмоида, PCA	Автоматически, допуск ±1%
B — верно/неверно	6	3 верных и 3 ложных, но правдоподобных утверждения	Автоматически (вердикт)
C — выбор метода	5	Инженерные ситуации: подшипники, станки, датчики	Вручную, двое вслепую, баллы 0–2
D — код sklearn	5	Короткие задания на sklearn	Запуск + чек-лист ошибок, двое вслепую
E — классификатор	1 опыт	AI4I 2020: 100 тестовых строк, 0/5/20 примеров	Автоматически
F — ловушки	10	6 изменённых копий задач A (для H1), 2 без нужных данных, 2 с лишними данными	Автоматически

Пилотные 5 задач нужны только для отладки промпта и в оценку не входят. Каждая задача пишется на русском и английском (так требует шаблон; английский делает Claude).

Тип E — что важно знать для защиты:

- Колонки TWF, HDF, PWF, OSF, RNF — это виды отказа, то есть **утечка ответа**. Их удаляем вместе с UDI и Product ID.
- Отказов в данных около 3,4%. Модель «всегда нет отказа» даёт accuracy около 96,6%. Поэтому смотрим F1 по классу «отказ» и balanced accuracy.
- В тест из 100 строк специально берём больше отказов (например, 20), иначе F1 не посчитать. В отчёте это честно описываем.
- Примеры для промпта берём только из обучающей части, 5 примеров входят в число 20, отказ есть в обоих наборах.

6. Метрики и графики (только обязательные)

- Точность по каждой модели и типу задач, 95% доверительный интервал бутстрепом.
- Тест Макнемара для всех 6 пар моделей.
- Доля отказов от ответа; баллы 0–2 для B и C; каппа Коэна для C и D.
- Для D: запустилась ли программа, верен ли результат, есть ли методологические ошибки.
- Для E: F1 класса «отказ», balanced accuracy, константный классификатор.
- Время ответа, токены, **рубли за один правильный ответ** по официальным тарифам; для локальной модели — время и память.
- Графики: тепловая карта «модель × тип», точность с интервалами, «стоимость — точность», по одному графику на гипотезу.

7. Кто что делает

Claude пишет весь код, черновик банка с проверенными в Python ответами, считает статистику, строит графики и собирает таблицы для отчёта. Выводы отчёта по правилам курса пишем сами.

	Ты (с Claude Code)	Аня
Подготовка	Ключ Yandex AI Studio, установка Ollama и Qwen3-4B, проверка, что все 4 модели отвечают	Читает этот план и задание (стр. 1–9)
Банк задач	Проверяет и решает типы C, D	Проверяет и решает на бумаге типы A, B, F; придумывает свои числа для изменённых задач
Прогоны	Запускает ноутбуки (на локальной модели — на ночь)	—
Тип E	Разбирается в подготовке данных и бейзлайнах	—
Анализ	Разбирается в бутстрепе, Макнемаре, расчёте стоимости	Выбирает 5 интересных ошибок моделей и разбирает их
Отчёт	Методика и результаты	Введение, разбор ошибок, ограничения, таблица рекомендаций

Только вместе:

- Выбрать гипотезы и написать прогноз → коммит до прогона.
- Отладить промпт на 5 пилотных задачах.
- **Слепая проверка C и D**: каждый участник ставит баллы в своей таблице, не видя, какая модель отвечала, и не обсуждая. Это 40 ответов на человека, примерно 1–1,5 часа. Если каппа < 0,6 — уточняем критерии и переоцениваем.
- Заключение отчёта и слайды доклада.
- Перед защитой опросить друг друга по 12 вопросам для самоконтроля (Claude подготовит шпаргалку с ответами на наших данных).

8. Порядок работы

№	Что	Кто	Время людей
1	Ключи, Ollama, git-репозиторий; проверка всех 4 моделей	Ты + Claude	~1 ч
2	Черновик банка от Claude → проверка и решение задач	Аня (A, B, F), ты (C, D)	~3 ч каждому
3	Гипотезы и прогноз → коммит	Вместе	~30 мин
4	Пилот на 5 задачах, промпт фиксируем	Вместе + Claude	~30 мин
5	Основной прогон + тип E	Claude, запускаешь ты	~1 ч + ночь для локальной модели
6	Слепая проверка C и D	Каждый отдельно	~1,5 ч каждому
7	Метрики, графики, таблицы	Claude	~30 мин на просмотр
8	Отчёт, доклад, подготовка к защите	Вместе	~4 ч каждому

9. Структура проекта

Файл	Что в нём
llm.py	Функция ask(model, prompt, temperature) → (ответ, токены, время), запись каждого ответа в JSONL
bank.csv, pilot.csv	Задачи с эталонами
hypotheses.md	Гипотезы и прогноз (коммит до прогона)

Файл	Что в нём
01_run.ipynb	Прогон банка через 4 модели и автопроверка
02_classification.ipynb	Тип E: AI4I, LLM и бейзлайны
03_analysis.ipynb	Метрики, интервалы, Макнемар, графики
review/	Слепые бланки C и D для двух проверяющих
results/, figures/	Ответы моделей, таблицы, картинки
requirements.txt, .env	Версии библиотек; ключи (не в git)

10. Что точно спросят на защите

- Почему temperature=0 не гарантирует воспроизводимость (поэтому все ответы сохраняем в файл).
- Почему accuracy 96% на AI4I — плохой результат (это уровень константы).
- Почему разница 34 из 40 против 31 из 40 может быть случайной (Макнемар смотрит только на задачи, где модели разошлись).
- Почему нельзя подгонять промпт под одну модель на тех же задачах (это как подбирать гиперпараметры на тесте — поэтому пилотные задачи отдельно).
- Как считать точность, если модель отказалась отвечать (два способа: отказ = ошибка; или точность только среди ответов).
- Задача про SVM: $w \cdot x + b = 3 \cdot 1 + 4 \cdot 0 - 2 = 1$, значит точка (1;0) лежит **ровно на границе зазора**; ширина зазора $2/\|w\| = 0{,}4$.
- Каждый участник должен уметь решить любую задачу A и F и объяснить любую ячейку кода.